

INFORME TÉCNICO FINAL

Sistema de Segmentación de Clientes para una PYME mediante Machine Learning

Autora

Mayra Sánchez

Fecha

13 de junio de 2026

Institución

UIDE — Universidad Internacional del Ecuador

1. INTRODUCCIÓN

El presente proyecto aplica técnicas de ciencia de datos y aprendizaje automático para segmentar clientes de una PYME, permitiendo identificar patrones de comportamiento de compra y diseñar estrategias comerciales diferenciadas por segmento. La segmentación de clientes es una herramienta fundamental en la gestión comercial moderna, ya que permite asignar recursos de manera eficiente y personalizar la experiencia del cliente según su perfil de consumo.

2. METODOLOGÍA

Se siguió la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), ampliamente utilizada en proyectos de ciencia de datos:

- **Comprensión del negocio:** identificar perfiles de clientes para optimizar estrategias de venta.
- **Comprensión de los datos:** dataset de 200 clientes con 4 variables (recencia, frecuencia, monto, productos).
- **Preparación de datos:** no se encontraron valores nulos; se normalizaron los datos con StandardScaler.
- **Modelado:** algoritmo K-Means con 4 clusters.
- **Evaluación:** análisis de perfiles por segmento.
- **Despliegue:** almacenamiento en base de datos SQLite.

3. HERRAMIENTAS UTILIZADAS

- Python 3.13 (Anaconda) — entorno de programación principal
- Pandas, NumPy — manipulación y procesamiento de datos
- Matplotlib, Seaborn — visualización de datos
- Scikit-learn — modelo de aprendizaje automático K-Means
- SQLite3 — base de datos relacional
- Jupyter Notebook en VS Code — entorno de desarrollo interactivo

4. ANÁLISIS EXPLORATORIO

El dataset contiene 200 clientes simulados con las siguientes variables cuantitativas. La recencia indica los días transcurridos desde la última compra del cliente; a menor recencia, mayor actividad reciente.

Variable	Media	Mínimo	Máximo
Recencia (días)	182	1	364
Frecuencia de compras	25	1	49
Monto total (USD)	158	0.5	743

Variable	Media	Mínimo	Máximo
Núm. de productos	10	1	19

No se encontraron valores nulos en ninguna variable, por lo que no fue necesario aplicar técnicas de imputación de datos.




Figura 1. Distribución de las variables del dataset. Se observa que la recencia se distribuye de forma uniforme, la frecuencia de compras tiende a concentrarse en valores medios, el monto total presenta una distribución exponencial con mayoría de clientes en montos bajos, y el número de productos se distribuye de forma dispersa.

5. RESULTADOS DEL MODELO

El modelo K-Means identificó 4 segmentos de clientes con perfiles claramente diferenciados:

Segmento	Nombre	Clientes	Recencia	Frecuencia	Monto USD
0	Inactivos	61	246.9 días	18.9	\$102
1	VIP	30	150.1 días	27.5	\$433
2	Frecuentes	63	151.2 días	40.0	\$95

Segmento	Nombre	Clientes	Recencia	Frecuencia	Monto USD
3	Ocasionales	46	189.3 días	15.7	\$98

Interpretación de segmentos

- **Clientes VIP (30 clientes):** alto monto de compra y frecuencia media. Son los clientes más rentables y merecen atención personalizada y programas de fidelización.
- **Clientes Frecuentes (63 clientes):** compran con alta frecuencia pero gastan poco por compra. Oportunidad para incrementar el ticket promedio mediante combos o promociones.
- **Clientes Ocasionales (46 clientes):** baja frecuencia y monto bajo. Requieren campañas de reactivación y ofertas de captación.
- **Clientes Inactivos (61 clientes):** no compran desde hace mucho tiempo. Se recomienda una estrategia de recuperación urgente con incentivos económicos.




Figura 2. Visualización de los 4 segmentos identificados por el modelo K-Means. El gráfico izquierdo muestra la relación entre frecuencia de compras y monto total, donde se aprecia claramente la separación entre segmentos. El gráfico derecho muestra la distribución de clientes por segmento, siendo los Clientes Frecuentes y los Clientes Inactivos los grupos más numerosos.

6. BASE DE DATOS

Los datos fueron almacenados en SQLite (`clientes_pyme.db`), una base de datos relacional ligera que permite realizar consultas SQL directamente desde Python. Se crearon dos tablas:

- **clientes:** tabla con los datos originales de los 200 clientes.
- **clientes_segmentados:** tabla con los datos originales más el segmento asignado por el modelo K-Means.

El script `db_integration.py` permite conectarse a la base de datos y realizar consultas en tiempo real, como obtener el listado de clientes VIP ordenados por monto de compra.

7. CONSIDERACIONES ÉTICAS

- Los datos utilizados son sintéticos, por lo que no existe riesgo de violación de privacidad ni protección de datos personales.
- En un caso real, se debe obtener el consentimiento informado de los clientes para el uso de sus datos en modelos predictivos.
- La segmentación no debe usarse para discriminar clientes sino para mejorar la calidad del servicio ofrecido.
- Se debe evitar el sesgo algorítmico revisando periódicamente los resultados del modelo con datos actualizados.
- El uso de inteligencia artificial en decisiones comerciales debe ser transparente, auditable y explicable.

8. CONCLUSIONES

- Se desarrolló exitosamente un sistema de segmentación de clientes utilizando el algoritmo K-Means.
- Se identificaron 4 perfiles de clientes con características y necesidades claramente diferenciadas.
- La integración con SQLite permite realizar consultas en tiempo real para la toma de decisiones comerciales.
- El segmento VIP representa solo el 15% de los clientes, pero genera el mayor valor económico para la PYME.
- Este tipo de análisis puede escalarse con datos reales para generar impacto directo en la rentabilidad del negocio.

9. REPOSITORIO DEL PROYECTO

Todo el código y los archivos generados están disponibles en la carpeta del proyecto:

- **segmentacion_clientes.ipynb** — Notebook principal con EDA, visualizaciones y modelo.
- **db_integration.py** — Script de integración con base de datos SQLite.
- **clientes_pyme.db** — Base de datos SQLite con los 200 clientes segmentados.
- **visualizacion_eda.png** — Gráfico de análisis exploratorio de variables.
- **segmentacion_clusters.png** — Gráfico de visualización de los clusters K-Means.